


שאלה 2

א.



ב. כן, ניתן לראות שהשגיאה הממוצעת קטנה ככול שגודל המדגם גדל, כמצופה שכן ככול שגודל המדגם גדל והשינוי ניכר במיוחד בקפיצות הראשונות שכן עבור $m=1$ השגיאה סביב 75% שהיא בעצם ממש תלויה בדגימה ודומה כמעט לתיוג אקראי, ואכן עבור מדגם אימון גדול יותר השגיאה נמוכה שכן ישנו כיסוי צפוף יותר של מרחב המאפיינים

ג. כן, ניכר שככול שגודל מדגם האימון גדל, הפערים בין השגיאה המקסימלית למינימלית קטנה יותר ויותר, זה ככול הנראה נובע מכך שככול שגודל מדגם האימון גדל, כל דגימה אקראית מייצגת בצורה טובה יותר את D ולכן הריצות השונות מניבות תוצאות עקביות יותר, הדבר נובע מחוק המספרים הגדולים השונות קטנה כש m גדל


ד. למרות המגמות השונות בגרפים נראה שעדיין עבור $k=1$ מתקבלת השגיאה הממוצעת הקטנה ביותר מבין כולם, וכן השגיאה גדלה יחד עם k שגדל באופן דיי עקבי אשר מתיישר עם טענה 3 עבור NN הנלמדה בהרצאה, זה נובע מהעובדה שא שעולה עבור m קבוע יוצר מצב בוא k מהווה נתח יותר ויותר גדול מדגימות ובכך מאבד מטיבו. כמו כן ניתן לשים לב שעבור $m=50$ כאשר k גדל נראה עליה גדולה יותר של השגיאה הנובעת לנבוע מהקרבה של k ל m שכן עבור $k=15$ מהווה 30% אחוז וכן

הטענה שנלמדה בהרצאה דורשת $\lim_{m \rightarrow \infty} \frac{k_m}{m} = 0$ וכן מאותה סיבה נקבל עליה קטנה יותר עבור


$m=400$


הגרפים:

a. $m=50$




b. $m=100$







.n
m=50 .a



m=100 .b



m=400 .c



1. עבור $m=50$ ניתן לראות ש- $k=1$ בעל הביצועים הטובים ביותר עבור $\text{noise} \in \{0\%, 5\%, 10\%\}$. תוצאה זו מתיישרת עם הסעיף הקודם שכן רמת הרעש נמוכה יחסית, עבור שאר רמות הרעש נראה ש- $k=7$ מפיק את התוצאה הטובה ביותר, עבור $m=100$ גם כאן כאשר אין רעש $k=1$ נותן את השגיאה הנמוכה ביותר מה שמתיישר עם התוצאה של סעיף ד', מכאן והילך $k=7$ נותן את השגיאה הטובה ביותר, עבור $m=400$ גם כן כמו בסעיף ד' $k=1$ הוא בעל השגיאה הנמוכה ביותר וכן עבור $\text{noise} \in 20\% - 5\%$ ולאחר מכן עבור 30% רעש, $k=15$ בעל השגיאה הנמוכה ביותר. כפי שציפיתי אכן כאשר אין רעש קיבלנו תוצאות זהות לסעיף ד', וכן גם ש- $k=1$ יניב שגיאה גבוהה עבור רעש גבוהה שכן סטטיסטית הסיכוי שהשכן היחיד שלך הוא רעש גבוהה יותר מאשר ש-7 או 15 שכנים הם כולם או רובם רעש, אך העבודה ש- $k=7$ הניב את התוצאה הטובה ביותר עבור רעש גבוהה הייתה לא צפויה עבורי, שכן אני ציפיתי שהמגמה יותר ויותר תהיה דומה לד' ככל ש- m גדל, אך נראה ש- $k=7$ באופן כמעט עקבי לאורך כל אחד מהגרפים נותן את התוצאה הטובה ביותר, אני ככל הנראה זה קורה מכיוון שמצד אחד ראינו ש- $k=1$ נותן שגיאה גבוהה כשהרעש גדל, אך מצד שני ראינו ש- $k=15$ נותן שגיאה נמוכה יותר עבור m נמוך יחסית ביחס עליו, ולכן התקבל ש-7 שנמצא ביניהם נותן את השילוב האידאלי שמצליח "להתחמק" מהרעש ובו זמנית להיות יותר טוב ביחס ל- m .

שאלה 3

א. נוכל להגדירם באופן הבא, נגדיר את X להיות בצמדים הסדורים (a, w) כאשר $a \in \{0, 1, \dots, 60\}$ הגיל ו- $w \in \{1, 2, 3, 4, 5\}$ משקלם, וכן את Y נגדיר להיות בינארי $Y \in \{0, 1\}$ כאשר 0 – lettuce ו-1 – carrot.

ב. עלינו לחשב $L_D(h_{\text{bayes}}) = \sum_{x \in X} \mathbb{P}[X = x](1 - \mathbb{P}[Y = h_{\text{bayes}}(x) | X = x])$

$\eta(x) := \mathbb{P}_{(X,Y) \sim D}[Y = y \mid X = x]$ וכן מתקיים $h_{\text{Bayes}}(x) := \mathbb{I}\{\eta(x) > \frac{1}{2}\}$
 לכן $\{(8,1), (8,3), (14,1), (14,3)\}$

$$h_{\text{bayes}}((8,1)) = \text{lettuce (1) ולכן } \eta((8,1)) = \frac{0.15}{0.15} = 1 > 0.5$$

$$h_{\text{bayes}}((8,3)) = \text{lettuce (1) ולכן } \eta((8,3)) = \frac{0.47}{0.47} = 1 > 0.5$$

$$h_{\text{bayes}}((14,1)) = \text{carrot (0) ולכן } \eta((14,1)) = \frac{0.18}{0.18} = 1 > 0.5$$

$$h_{\text{bayes}}((14,3)) = \text{lettuce (1) ולכן } \eta((14,3)) = \frac{0.20}{0.20} = 1 > 0.5$$

כלומר

$$L_D(h_{\text{bayes}}) = \mathbb{P}[X = (8,1)](1 - \eta_1((8,1))) + \mathbb{P}[X = (8,3)](1 - \eta_1((8,3))) \\ + \mathbb{P}[X = (14,1)](1 - \eta_0((14,1))) + \mathbb{P}[X = (14,3)](1 - \eta_1((14,3))) = 0$$

ג.

age	Preferred food	Probability
8	lettuce	62%
14	lettuce	20%
14	carrot	18%

ד. המפתחות בתמיכה: $\{8,14\}$

$$h'_{\text{bayes}}(8) = \text{lettuce (1) ולכן } \eta'(8) = \frac{0.62}{0.62} = 1 > 0.5$$

$$h'_{\text{bayes}}(14) = \text{lettuce (1) ולכן } \eta'(14) = \frac{0.20}{0.38} > 0.5$$

ולכן ה Bayes-optimal error יהיה:

$$L_D(h'_{\text{bayes}}) = \mathbb{P}[X = 8](1 - \eta'_1(8)) + \mathbb{P}[X = 14](1 - \eta'_1(14)) \\ = 0.62 \cdot (1 - 1) + 0.38 \cdot \left(1 - \frac{0.20}{0.38}\right) = 0.18$$

שאלה 4

א. נשתמש בנוסחה מההרצאה:

$$L_D(h_{+1}) = \mathbb{P}_{(X,Y) \sim D}[h_{+1}(x) \neq Y] = \mathbb{P}_{(X,Y) \sim D}[+1 \neq Y] = \mathbb{P}_{(X,Y) \sim D}[-1 = Y] \stackrel{\text{def}}{=} p$$

ב. ע"פ הגדרה $\mathbb{P}_{(X,Y) \sim D}[Y = -1] = p$ ולכן,

$$\mathbb{P}_{S \sim D^m}[y_i = +1 \text{ for all } i \in \{1, \dots, m\}] \\ = \prod_{i=1}^m \mathbb{P}[y_i = +1] \\ = \prod_{i=1}^m (1 - \mathbb{P}[y_i = -1]) = (1 - p)^m \leq \text{טיילור פיתוח} e^{-mp} \leq e^{-\epsilon p} e^{-\epsilon m}$$

ג. נגדיר את A' :

בהינתן מדגם $S = \{(x_1, y_1), \dots, (x_m, y_m)\}$, אם קיים $(x_i, y_i) \in S$ כך ש $y_i = -1$ תריץ את A והחזר את h שהאלג' מחזיר, אחרת h_{+1}

נכונות:

נצטרך להראות שלכל $\epsilon, \delta \in (0, 1)$, ולכל הסתברות D קיים $m(\epsilon, \delta)$ גודל המדגם כך שבהסתברות של לפחות $(1 - \delta)$ על בחירת S מתקיים:

$$\mathcal{L}_D(h_S) \leq \epsilon$$

נפצל ל2 מקרים:

1. עבור $D \in \mathcal{D}_{bad}$ לכל S שנבחר האלגוריתם יחזיר h_+ ועבורו מתקיים $0 \leq \mathcal{L}_D(h_+) = 0$ וכן זה קורה בהסתברות 1 שגדולה מ $1 - \delta$ וקיבלנו ש' $PAC\text{-}learner$

2. עבור $D \in \mathcal{D}_{good}$ יהי $\epsilon, \delta \in (0, 1)$ נפצל ל2 מקרים:

a. עבור $p < \epsilon$, במקרה זה נשתמש בסעיף ב, נסמן נגדיר את m כך:

$$m = \max\left(\frac{\log\left(\frac{2}{\delta}\right)}{\epsilon}, m_A\left(\epsilon, \frac{\delta}{2}\right)\right)$$

עבור m מסעיף במתקיים:

$$\mathbb{P}_{S \sim D^m}[y_i = +1 \text{ for all } i \in \{1, \dots, m\}] \leq e^{-m\epsilon} \leq \frac{\delta}{2}$$

כלומר בהסתברות של לכל היותר $\frac{\delta}{2}$ נבחר מדגם כך שהאלג' יחזיר את h_{+1} ויכשל, ומכיוון ש A $PAC\text{-}learner$ ובחרנו m מספיק גדול נקבל שעבור A יבחר מדגם שעבורו A ייכשל בהסתברות של לכל היותר $\frac{\delta}{2}$ ולכן בסה"כ נקבל שהאחד מהמאורעות (אשר זרות זו לזו) יקרו (כלומר A' ייכשל עבור המדגם שנבחר) בהסתברות δ כלומר בסה"כ נקבל שתנאי המשפט מתקיים ולכן A' הוא $PAC\text{-}learner$

b. עבור $\epsilon \geq p$: במקרה זה לא משנה מה האלגוריתם יריץ את A נקבל h_S כלשהו ומכיוון ש A $PAC\text{-}learner$ נקבל שבהסתברות $1 - \delta$ $\mathcal{L}_D(h) \leq \epsilon$ ובמקרה ש' A' יחזיר את h_{+1} נקבל $\epsilon \leq \mathbb{E}[\mathcal{L}_D(h_{+1})] \leq p$ כלומר בסה"כ נקבל שתנאי המשפט מתקיים ולכן A' הוא $PAC\text{-}learner$

כלומר בסה"כ קיבלנו ש' A' הוא $PAC\text{-}learner$

שאלה 5

נראה שה $VCdim$ של $\mathcal{H}_{thr}$ הוא 2:

שלב 1:

נבחר $x^{(1)} = (1, 2), x^{(2)} = (2, 1) \in \mathcal{X} = \mathbb{R}^2$ נחלק ל4 מקרים:

1. $h(x^{(1)}) = h(x^{(2)}) = +1$ נבחר $h_{1,0}$ ומתקיים $1 - 0 > 0 \wedge 2 - 0 > 0$ ולכן $h_{1,0}(x^{(1)}) = h_{1,0}(x^{(2)}) = +1$

2. $h(x^{(1)}) = h(x^{(2)}) = -1$ נבחר $h_{1,3}$ קל לראות שמתקיים $h_{1,3}(x^{(1)}) = h_{1,3}(x^{(2)}) = -1$

3. $h(x^{(1)}) = -1, h(x^{(2)}) = +1$ נבחר $h_{1,1.5}$ עבורו מתקיים $1 - 1.5 < 0 \wedge 2 - 1.5 > 0$ ולכן $h_{1,1.5}(x^{(1)}) = -1$ וכן $h_{1,1.5}(x^{(2)}) = +1$

4. $h(x^{(1)}) = +1, h(x^{(2)}) = -1$ נבחר $h_{2,1.5}$ וקל לראות שמתקיים $h_{2,1.5}(x^{(1)}) = +1$ ו $h_{2,1.5}(x^{(2)}) = -1$

כלומר בסה"כ קיבלנו ש $VCdim(\mathcal{H}_{thr}) \geq 2$

שלב 2:

יהיו $x^{(1)}, x^{(2)}, x^{(3)} \in \mathcal{X}$ כלשהן, נראה שקיים תיוג שלא מנותץ ע"י $\mathcal{H}_{thr}$, נסמן את הנקודה בה x_1 הוא הקטן ביותר ב a ואת הערך שלו ב a_1 ואת הנקודה בה x_2 הוא קטן ביותר ב a_2 ואת ערכו ב a_2 נסתכל על התיוג הבא:

$h(a) = h(t) = +1$ וכן את הנקודה השלישית נתייג כ-1 נשים לב שבמקרה בו $a=t$ כלומר אותה נקודה פשוט נסמן את 2 הנקודות האחרות ב-1 ונראה שתיוג זה אינו מנותץ ע"י $\mathcal{H}_{thr}$:

- עבור $i = 1$ a היא הנק' בעלת ה x_1 הקטן ביותר ולכן כדי שתתויג +1 עלינו לקבוע $b < a_1$ מה שיתייג את כל הנקודות כ-1 + בסתירה לתיוג שנקבע
- עבור $i = 2$ b היא הנקודה בעלת ה x_2 הקטן ביותר ולכן כדי שתתויג +1 עלינו לקבוע $b < t_1$ מה שיתייג את כל הנקודות כ-1 + בסתירה לתיוג שנקבע

כלומר בסה"כ קיבלנו לכל 3 נקודות ב- $\mathcal{X}$ ישנו תיוג שלא ניתן לניתוח ע"י $\mathcal{H}_{thr}$ ולכן מתקיים $VCdim(\mathcal{H}_{thr}) < 3$
כלומר בסה"כ קיבלנו ש $VCdim(\mathcal{H}_{thr}) = 2$